

INTRODUÇÃO

Apesar dos avanços em *Automated Essay Scoring* (AES) para o português, quase todos os modelos usam apenas redações de simulados. Este trabalho investiga quatro questões centrais:

- Os simulados são realmente parecidos com as redações oficiais?
- Modelos treinados só em simulados corrigem textos reais?
- O que ocorre ao treinar apenas no conjunto oficial (pequeno)?
- O pré-treino em simulados melhora a correção de textos oficiais?

METODOLOGIA

1. Coleta de dados

- Envio voluntário de redações oficiais via formulário online.
- Digitalização de textos manuscritos com apoio de LLMs.
- Revisão manual para garantir fidelidade total ao texto original.

2. Análise linguística

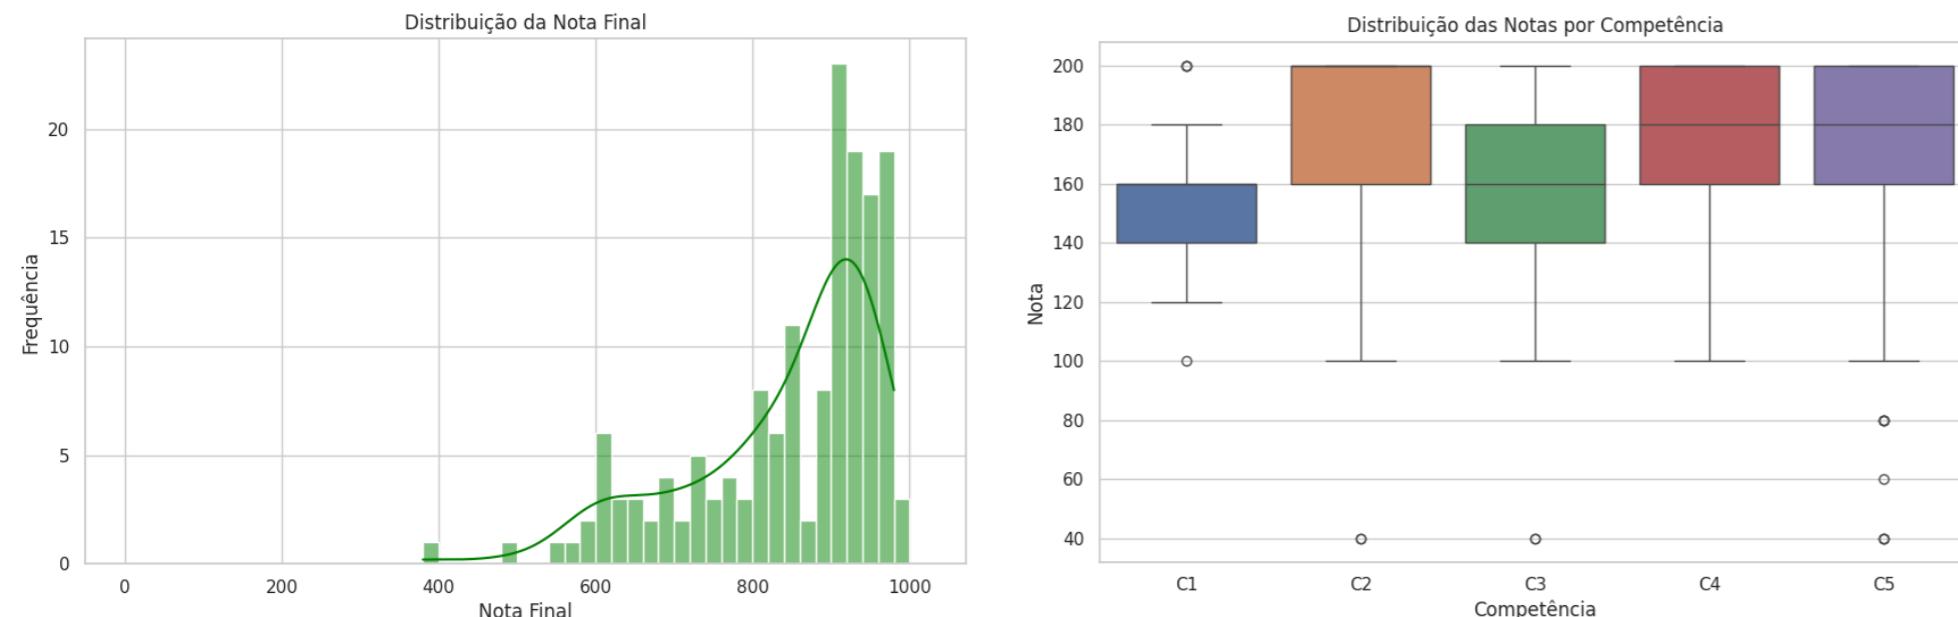
- Extração de 72 métricas textuais usando o NILC-Metrix.
- Modelos de regressão linear por competência (C1–C5).
- Identificação das métricas linguísticas mais influentes na nota.

3. Experimentos com encoders

- Modelos avaliados: mBERT, BERTuguês e BERTimbau.
- Três cenários experimentais:
 - *Zero-shot*: uso direto sem ajuste.
 - *Pretrained Fine-tuning*: pré-treinado + ajustado no oficial.
 - *Exclusive Fine-tuning*: ajustado apenas nas redações oficiais.
- Divisão: 114 redações para treino, 43 para teste.
- Ajuste por *grid search* e validação cruzada.

RESULTADOS E DISCUSSÃO

Foram coletadas 157 redações oficiais do ENEM, incluindo o texto completo, o ano da prova e as notas oficiais em todas as competências.



Distribuição das notas: predominância de notas altas, reflexo do perfil dos participantes.

Análise textual: A regressão linear mostrou que as mesmas métricas linguísticas (substantivos, palavras de conteúdo, verbos, adjetivos e advérbios) dominam a predição das 5 competências. Esse padrão, também presente nos simulados, indica forte semelhança linguística e reforça que simulados são eficazes para pré-treinamento.

Experimentos com encoders

Tabela 1: QWK em todos os experimentos

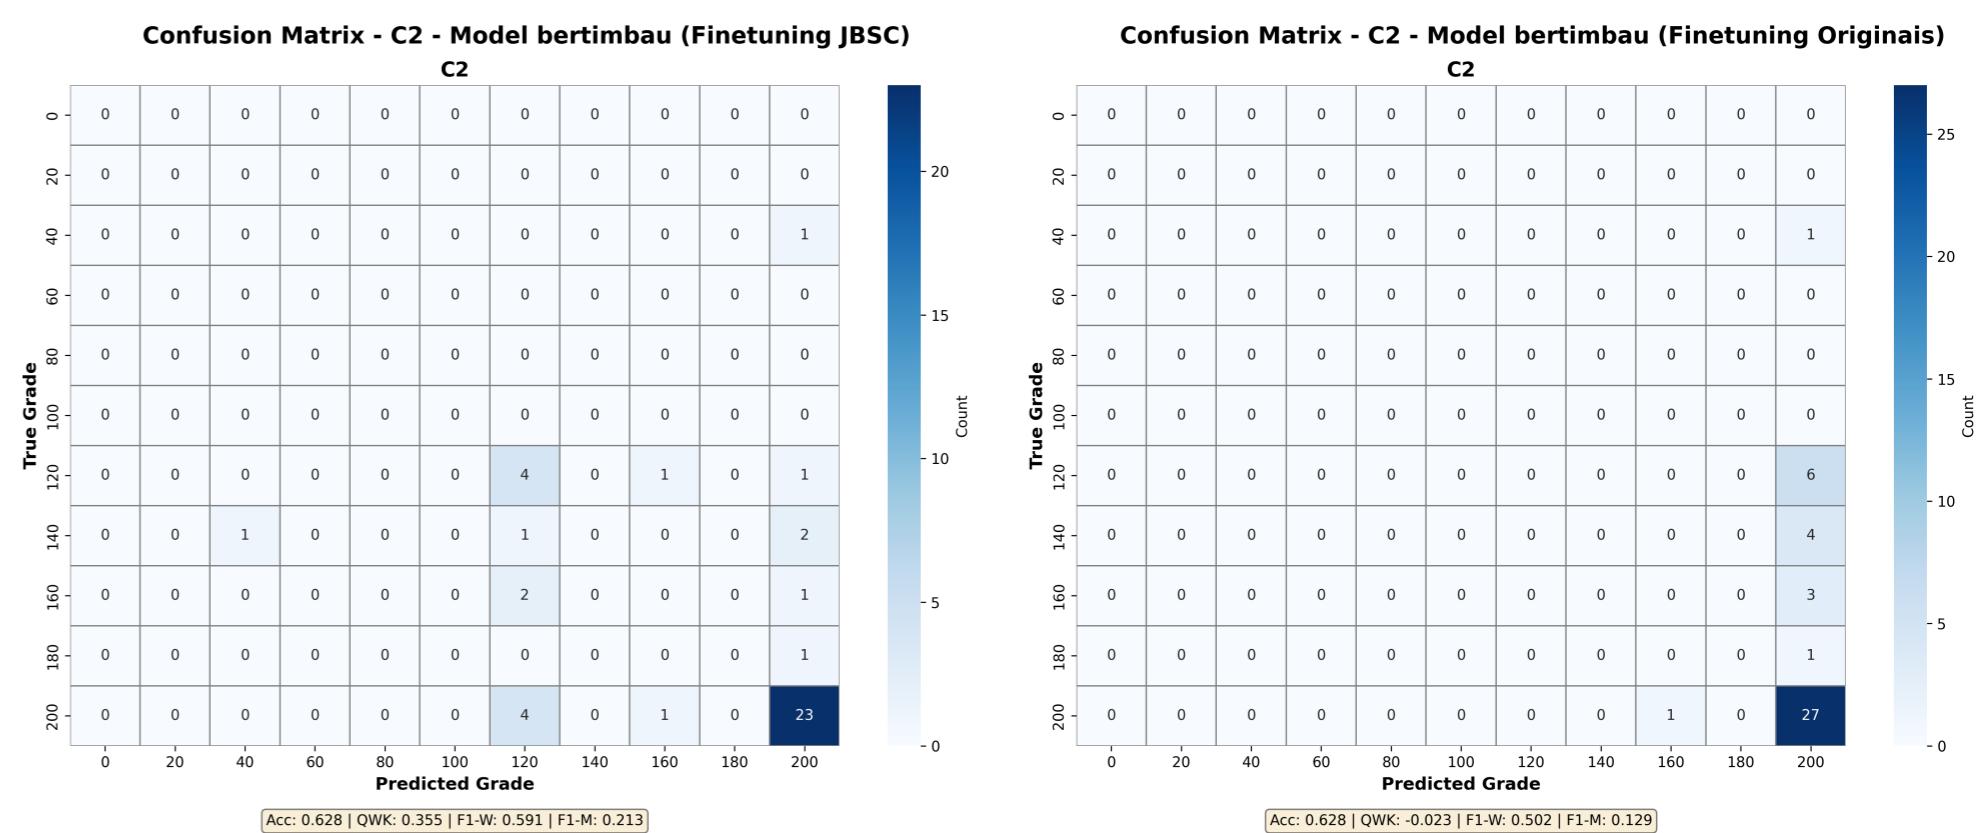
| | mBERT | | | | | BERTuguês | | | | | BERTimbau | | | | |
|---------------|-------|------|------|------|---------|-----------|------|------|------|---------|-----------|------|------|-------|---------|
| | C1 | C2 | C3 | C4 | C5 avg. | C1 | C2 | C3 | C4 | C5 avg. | C1 | C2 | C3 | C4 | C5 avg. |
| Mock Exams | .520 | .220 | .350 | .500 | .000 | .318 | .620 | .330 | .290 | .540 | .360 | .428 | .600 | .360 | .350 |
| Zero-shot | .501 | .349 | .447 | .626 | .030 | .391 | .382 | .375 | .290 | .619 | .271 | .387 | .378 | .253 | .387 |
| Pretrained FT | .456 | .464 | .519 | .727 | .000 | .433 | .467 | .449 | .286 | .685 | .489 | .475 | .393 | .355 | .453 |
| Exclusive FT | .000 | .348 | .000 | .272 | .359 | .196 | .073 | .313 | .150 | .315 | .020 | .174 | .000 | -.023 | .000 |

Tabela 2: F1 ponderado em todos os experimentos

| | mBERT | | | | | BERTuguês | | | | | BERTimbau | | | | |
|---------------|-------|------|------|------|---------|-----------|------|------|------|---------|-----------|------|------|------|---------|
| | C1 | C2 | C3 | C4 | C5 avg. | C1 | C2 | C3 | C4 | C5 avg. | C1 | C2 | C3 | C4 | C5 avg. |
| Zero-shot | .373 | .571 | .143 | .334 | .002 | .285 | .296 | .565 | .221 | .369 | .272 | .345 | .302 | .517 | .193 |
| Pretrained FT | .375 | .630 | .209 | .354 | .180 | .350 | .372 | .625 | .195 | .376 | .373 | .388 | .360 | .591 | .183 |
| Exclusive FT | .271 | .608 | .088 | .260 | .386 | .323 | .289 | .595 | .161 | .280 | .187 | .302 | .271 | .502 | .088 |

Zero-shot: modelos pré-treinados em simulados já apresentam bom desempenho inicial, indicando transferência efetiva para redações oficiais.

Pretrained fine-tuning: o ajuste com poucas redações oficiais produz os melhores resultados e maior estabilidade, superando os demais cenários em QWK e F1.



Exclusive fine-tuning: o modelo teve a previsão concentrada em poucas classes, resultando em um QWK muito baixo; mesmo o F1, menos penalizado por previsões homogêneas, permanece inferior ao cenário pré-treinado.

CONCLUSÃO

- Redações simuladas e oficiais apresentam alta semelhança linguística
- Simulados são muito mais abundantes e de coleta simples
- Pré-treinamento em simulados melhora consistentemente o desempenho dos modelos.
- Ajustar o modelo apenas com um pequeno conjunto oficial garante adaptação ao padrão real de correção.

A estratégia mais eficaz para AES no ENEM é pré-treinar em grandes conjuntos de simulados e fazer fine-tuning final com poucas redações oficiais.

REFERÊNCIAS

1. Silveira, I. C.; Barbosa, A.; Mauá, D. D. *A New Benchmark for Automatic Essay Scoring in Portuguese*. PROPOR, 2024.
2. Leal, S. E.; Duran, M. S.; Scarton, C.; Aluísio, S. M. *NILC-Metrix: Assessing the Complexity of Written Language in Brazilian Portuguese*. Language Resources and Evaluation, 2024.
3. Barbosa, A.; Silveira, I. C.; Mauá, D. D. *An Empirical Analysis of Large Language Models for Automated Cross-Prompt Essay Trait Scoring in Brazilian Portuguese*. Journal of the Brazilian Computer Society (JBCS), 2025.
4. Devlin, J.; Chang, M.-W.; Lee, K.; Toutanova, K. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. NAACL, 2019.